



Fórmula 1: 1950-2026

Esse dataset no [kaggle](https://www.kaggle.com) possui todas as informações da primeira temporada até os dias de hoje (1950-2026). Há dados sobre corridas, pilotos, equipes, corridas qualificatórias, Grand Prix, etc.

Os dados escolhidos foram especificamente os de resultado das corridas de Grand Prix, tendo dados sobre pontuação, grid de largada, nome dos pilotos, equipes, vitórias, acidentes, etc.

Overview do ETL

Além das libs recomendadas, fiz uma adição fora da lista da Pathlib, que serve para gerir Path de arquivos com maior facilidade, e que também foi utilizada no exemplo do Titanic, que foi passada em aula.

Começando pela extração, como os dados foram baixados diretamente com CSV, a função `extract_data` serve só para ler os dados da pasta `raw/` e retorna o DF daquele CSV.

Existia a possibilidade de fazer uma chamada de API comum, mas só consegui baixar o dataset completo, não só um arquivo específico. Então optei por baixar o CSV manualmente.

Na `transform_data`, escolhi quebrar as etapas em funções específicas, para ter um controle melhor e escalabilidade das funções. Temos uma função para dropar colunas, uma para renomear, uma para deduplicar, uma para limpar e cuidar dos dados nulos e a função final que cuida de cada uma dessas chamadas e retorna o DataFrame para a load. A função `<handle_nulls>` poderia ter sido mais otimizada, mas creio que esteja ok para o momento.


As decisões de qualidade de dados tomadas foram: Verificar valores nulos, verificar duplicidades, verificar tipos incorretos, remover colunas desnecessárias. Havia um total de 25939 linhas, e depois de remover as duplicatas o valor continua o mesmo, pois não havia dados duplicados. Já sobre os nulos, havia 51893 registros, mas após tratamento foram zerados.

Na load_data, os dados são carregados na pasta processed/.


EDA - Análise Exploratória

Hipóteses levantadas e Perguntas respondidas


1. Quais são os melhores pilotos?
2. Quantas vezes esses pilotos ganharam?
3. Dos que ganharam, a posição de largada importa?
4. A equipe a qual pertence importa?
5. Esse comportamento varia de acordo com o tempo?




1.




2.



3.



4.



5.

Conclusões

- Pole positions possuem forte correlação com vitórias;
- Décadas recentes mostram maior previsibilidade;
- Equipes dominantes concentram grande parte dos pontos;
- A F1 moderna depende mais de qualifying.